# 面向小型无人机场景的动作条件隐空间预测与局部路径修正

**摘要**

被动观测的视频预测只能回答“接下来画面会如何变化”，无法回答“执行某个动作会如何变化”，后者才是决策所需。本文以仿真为数据来源，构建一个约 5 M 参数的隐空间预测模型，输入 8 帧观测与候选动作，输出未来 1 秒的占据分布，并将其接入分层规划框架：全局路径由 A* 生成，模型仅修正在途的局部路径。在同一全局路径下对照“以当前帧判断安全性”与“以模型预测判断安全性”的碰撞次数，实验表明 [待补：核心数字]。

**关键词**：隐空间预测；动作条件；无人机避障；分层规划

## 1 引言

无人机在小型农业与园区巡检中的应用逐渐增多。此类场景地块面积小、分布分散、边界不规则，大型农机难以适配，作业主要依赖小型多旋翼飞行器。在这类环境中，飞行器需要在视野受限的条件下判断“接下来哪些区域会被占据”，以支持避障与路径调整。

现有的视频预测方法多针对被动观测，回答的是“接下来画面会如何变化”，而不回答“如果执行某个动作会如何变化”。后者才是决策所需的信息，其建模要求将动作作为显式输入。

将动作引入预测模型，存在三个具体困难。

**其一，缺少动作条件的数据。**公开的无人机视觉数据集以检测与跟踪为目标构建，只提供图像与目标框，不含相机位姿与飞控指令，无法支撑动作条件预测的训练与评估。

**其二，缺少有判别力的评估指标。**在持续性主导的场景中，全图 IoU 会被大量静止区域稀释。本文在 VisDrone 上的实测显示，“未来等于现在”的平凡基线在预测 5 步后仍取得 0.406 的全图 IoU，该指标不足以判别模型是否学到动力学。

**其三，小模型下的表征坍缩。**隐空间预测存在退化解：当编码器对所有输入输出同一向量时，预测误差为零而表征不含信息。抑制该解需要两个约束，即目标编码器的指数滑动平均（EMA）与表征的方差/协方差正则（VICReg）。

针对上述问题，本文以仿真为数据来源构建动作条件世界模型，并将其接入分层规划框架。工作内容如下：

1. **数据**：在 Unreal Engine 中建立采集管线，同步记录相机画面、位姿、飞控动作与占据真值，形成具有因果结构的数据集；
2. **模型**：训练约 5 M 参数的隐空间预测模型，输入为 8 帧观测与候选动作，输出未来 1 秒的占据分布，以 EMA 目标编码器与 VICReg 抑制坍缩；
3. **系统**：全局路径由 A* 依据静态地图生成，世界模型仅修正在途的局部路径，使“世界模型的价值”与“全局规划的价值”解耦；

4. **评估**：在同一全局路径下，对照“以当前帧判断安全性”与“以模型预测判断安全性”的碰撞次数。

本文全部实验在仿真中完成，不包含真机验证，也不包含风扰、通信延迟等真实扰动。

# 2 相关工作

## 2.1 隐空间预测

[待补：200 字：JEPA 与 V-JEPA 的预测目标；VICReg 的方差/协方差约束；为何不在像素空间预测]

## 2.2 无人机视觉导航中的世界模型

[待补：150 字：MAD 以占据/可见性图为预测目标；AirDreamer 的 Dreamer 式结构；Flow-Pilot/AeroAct 将世界模型限制在训练阶段]

## 2.3 分层规划

[待补：80 字：全局规划与局部修正的经典两段式；本文沿用该结构以便解耦评估]

# 3 方法

## 3.1 数据采集

[待补：250 字：场景构成、采集内容（画面/位姿/动作/占据）、动作定义、分辨率与帧率]

## 3.2 模型结构

[待补：300 字：编码器、预测器、EMA 目标、探针；参数量与显存]

## 3.3 训练目标

预测损失定义为预测表征与目标表征之间的余弦距离：

$$\mathcal{L}_{\text{pred}} = \frac{1}{K}\sum_{k=1}^{K}\Big(1-\cos\big(\hat{z}_{t+k},\, z_{t+k}\big)\Big), \tag{1}$$

并以 VICReg 的方差项与协方差项约束表征：

$$\mathcal{L} = \mathcal{L}_{\text{pred}} + \lambda_{\text{var}}\mathcal{L}_{\text{var}} + \lambda_{\text{cov}}\mathcal{L}_{\text{cov}}. \tag{2}$$

[待补：补：各项的作用与取值]

## 3.4 规划接口

[待补：200 字：A* 生成全局路径；每 0.5 s 用模型预测局部占据并判断安全性；必要时横向偏移]

# 4 实验

## 4.1 设置

[待补：150 字：数据规模、训练配置、评估指标定义]

## 4.2 正则强度的影响

在真实数据上对正则权重 $\lambda_{\text{var}}$ 做三点对照，结果见表 1。权重过小时表征坍缩，隐空间余弦接近 1 而下游指标全部归零；权重过大时表征过于分散，下游精度下降。中间取值在综合指标上最优。

表 1 正则权重对照（真实数据，预测时域 5 步）。$\lambda_{\text{var}} = 0.05$ 时探针不产生任何正预测，下游指标为零。

| $\lambda_{\text{var}}$ | 闭环余弦 | $R_{\text{new}}$ | $P_{\text{occ}}$ | F1 | IoU |
|---|---|---|---|---|---|
| 0.05 | 0.905 | 0.000 | 0.000 | 0.000 | 0.000 |
| 0.10 | 0.640 | 0.349 | 0.412 | **0.378** | **0.190** |
| 0.15 | 0.306 | **0.507** | 0.179 | 0.265 | 0.127 |
| 平凡基线 | — | 0.000 | — | — | 0.406 |

## 4.3 主结果

[待补：250 字 + 表：碰撞次数对照（用当前帧 vs 用模型预测）]

## 4.4 消融

[待补：150 字：有动作 / 无动作 / 恒等基线三组]

# 5 讨论

## 5.1 隐空间误差不能作为评价指标

表 1 中，$\lambda_{\text{var}} = 0.05$ 的模型取得最高的闭环余弦（0.905），但其下游指标全部为零。这说明隐空间预测误差在表征坍缩时会给出与真实能力相反的排序，评估必须以下游任务为准。

## 5.2 增益来源

[待补：200 字：动作条件带来的增益来自何处；与“用当前帧”的差异分析]

# 6 局限与展望

本文的工作有以下边界：全部实验在仿真中完成，未经真机验证；动作不含噪声，未建模通信延迟与风扰；预测时域为 1 秒，未涉及多机协同与长时域规划；仅建模飞行动作，未涉及农事作业动作。

后续工作的一个方向是多模态融合。实际系统中观测将来自多光谱、热红外与地面传感器，其采样率与坐标系并不一致。隐空间预测不要求像素级对齐，为该类融合提供了接口。

# 7 结论

[待补：100 字：三条结论]

# 参考文献